

ECO5008 Modelos predictivos

Clase 02 - Modelos de Supervivencia y Weibull aplicados a Salud

Sebastián Egaña Santibáñez 

Enlaces del profesor

 <https://segana.netlify.app>

 <https://github.com/sebaegana>

 <https://www.linkedin.com/in/sebastian-egana-santibanez/>

Clase 02

Conceptos iniciales

Introducción a supervivencia

Cuando hablamos de supervivencia en términos de predicciones nos referimos al esfuerzo de modelar el tiempo que transcurre hacia cierto evento. En el caso del área de salud, podemos pensar en el tiempo que transcurre hasta remisión, alta o rehospitalización. Un área intermedia de aplicación, corresponde a la de ingeniería de la confiabilidad, sirviendo para poder determinar tiempo entre fallas o entre reparaciones.

Elementos claves

- La variable relevante para ser analizada corresponde al tiempo hasta el evento, considerando $T > 0$
- Censura: corresponde a evento que por alguna u otra razón no puede ser observado de manera completa; por ejemplo, si estamos analizando el tiempo antes del alta de los pacientes existirán casos de paciente que aún se encuentran hospitalizados pero que dado el momento de selección del estudio debemos **censurar** en base al valor que posee al momento del estudio. Este tipo de observación solo **añade** a la probabilidad de que el evento ocurra posterior a lo observado y debe ser marcada para incorporarla de manera distinta al análisis.

Tipos de censura (diagrama)

Leyenda

- - tiempo observado
- [inicio
-] fin
- | corte/fin
- * evento observado
- ? evento en el intervalo

1) Evento observado (no censurado)

Sujeto A: [-----*-----] → observamos $T = t$

2) Censura a derecha (right censoring)

Sujeto B: [-----|] → sabemos $T > C$
(no ocurrió antes del corte)

3) Censura a izquierda (left censoring)

Sujeto C: [*-----] → sabemos $T \leq L$
(ocurrió antes del 1er registro)

4) Censura por intervalo (interval censoring)

Sujeto D: [---?---] → sabemos $L < T \leq R$
(entre dos visitas y relacionada con inspecciones)

5) Censura administrativa (Tipo I, corte común de calendario)

Sujeto E: [-----|] → típicamente "a derecha"

6) Censura Tipo II (por número de eventos)

Cohorte: el estudio termina cuando ocurre el k -ésimo evento

Preguntas

¿Considere en los casos de gestión para los cuales esto podría ser valioso?

Distribución de Weibull

Se utiliza para modelos los tiempos hasta un evento cuando la tasa de eventos cambia de forma monótona (crece o decrece).

Parámetros.

k (forma): indica cómo cambia el riesgo en el tiempo.

- $k > 1$: riesgo creciente (cada vez más probable el evento).
- $k = 1$: riesgo constante (caso exponencial).
- $k < 1$: riesgo decreciente (más probable al inicio).

λ (escala): fija la escala temporal (en las mismas unidades que t).

Se puede calcular con covariables (otras variables relevantes), pero para este caso solo utilizaremos la función sin otras variables.

Fórmulas clave (Weibull)

Sea $T \sim \text{Weibull}(k, \lambda)$ con $k > 0$ (forma) y $\lambda > 0$ (escala), $t \geq 0$.

- PDF (Weibull): $f(t) = \frac{k}{\lambda} \left(\frac{t}{\lambda}\right)^{k-1} \exp[-(t/\lambda)^k]$
- CDF: $F(t) = 1 - \exp[-(t/\lambda)^k]$
- Supervivencia: $S(t) = \exp[-(t/\lambda)^k]$
- Riesgo (hazard): $h(t) = \frac{k}{\lambda} \left(\frac{t}{\lambda}\right)^{k-1}$
- Riesgo acumulado: $H(t) = -\ln S(t) = (t/\lambda)^k$
- Percentil p : $t_p = \lambda [-\ln(1-p)]^{1/k}$
- Mediana: $t_{0.5} = \lambda (\ln 2)^{1/k}$
- Media: $\mathbb{E}[T] = \lambda \Gamma\left(1 + \frac{1}{k}\right)$

En la práctica, el software (R en este caso) te devuelve k , λ , la media, la mediana y los intervalos sin que tengas que calcularlos a mano.

Ejemplo simplificado

Tenamos los siguientes datos de altas pacientes con neumonía y queremos predecir el tiempo promedio de hospitalización en días:

```
tiempo <- c(2,3,1,5,7,8,9,3,4,6,2,10,11,7,5,4,12,8,9,6)
alta    <- c(1,1,1,1,1,0,0,1,1,1,1,0,0,1,1,1,0,1,1,1)
```

Recordar que acá la censura corresponde a los pacientes que no han sido dados de alta (alta = 0).

Table 1: Conteos: total, eventos (DELTA=1), censuras (DELTA=0)

Total	Eventos_DELTA1	Censuras_DELTA0	Proporcion_evento
20	15	5	0.75

Table 2: Resumen global de TCC (días)

n	min	mean	sd	median	max
20	1	6.1	3.161	6	12

Table 3: Resumen de TCC por estado DELTA (días)

DELTA	n	min	mean	sd	median	max
0	5	8	10.0	1.581	10	12
1	15	1	4.8	2.366	5	9

Veamos el análisis de Weibull para estos datos:

Table 4: Parámetros Weibull 2P por caso

Caso	shape (k)	scale ()
Sin censura	2.2424	5.4240
Con censura	1.5848	7.8569

Table 5: Mediana, media y percentiles t_p ($p=0.1, 0.5, 0.9$)

Caso	Mediana	Media	$p=0.1$	$p=0.5$	$p=0.9$
Sin censura	4.6061	4.8041	1.9883	4.6061	7.8678
Con censura	6.2347	7.0506	1.8993	6.2347	13.2985

Actividad aplicada

Recuerden, seguimos siendo un equipo de analistas. Tenemos datos relacionados con tiempo de cirugías cardíacas en donde nuestro interés se relaciona con estimar el tiempo de la operación hasta que un paciente muere.

Estimación de Weibull

EDA

Veamos algunas estadísticas descriptivas:

Table 6: Conteos: total, eventos (DELTA=1), censuras (DELTA=0)

Total	Eventos_DELTA1	Censuras_DELTA0	Proporcion_evento
145	139	6	0.959



Table 7: Resumen global de TCC (horas)

n	min	mean	sd	median	max
145	1.92	5.329	1.979	5.25	14.17

Table 8: Resumen de TCC por estado DELTA (horas)


DELTA	n	min	mean	sd	median	max
0	6	2.92	5.127	1.644	5.71	6.67
1	139	1.92	5.338	1.997	5.17	14.17

Consideremos realizar un histograma para ver la distribución de las horas de operación:




Otros gráficos relevantes:

Boxplot de TCC por estado



ECDF de TCC (global)



Weibull 2P: cálculo con y sin censura

Table 9: Parámetros Weibull 2P por caso

Caso	shape (k)	scale ()
Sin censura (DELTA==1)	2.8331	5.9906
Con censura (Surv)	2.8574	6.0694

Table 10: Funciones evaluadas en $t = p10, p30, p50, p70, p90$ del TCC

Caso	Funcion	t=3	t=3.84	t=5.25	t=6.33	t=7.85
Sin censura	PDF $f(t)$	0.115615	0.157600	0.186599	0.162547	0.090246
Sin censura	CDF $F(t)$	0.131477	0.246994	0.497462	0.689321	0.883794
Sin censura	Supervivencia $S(t)$	0.868523	0.753006	0.502538	0.310679	0.116206
Sin censura	Riesgo $h(t)$	0.133117	0.209294	0.371313	0.523198	0.776602
Sin censura	Riesgo acum. $H(t)$	0.140961	0.283682	0.688084	1.168995	2.152394
Con censura	PDF $f(t)$	0.111282	0.153514	0.185735	0.164822	0.094210
Con censura	CDF $F(t)$	0.124993	0.236878	0.483528	0.676210	0.875969
Con censura	Supervivencia $S(t)$	0.875007	0.763122	0.516472	0.323790	0.124031
Con censura	Riesgo $h(t)$	0.127179	0.201165	0.359622	0.509042	0.759569
Con censura	Riesgo acum. $H(t)$	0.133524	0.270337	0.660735	1.127662	2.087224

Table 11: Mediana, media y percentiles t_p ($p=0.1, 0.5, 0.9$)

Caso	Mediana	Media	p=0.1	p=0.5	p=0.9
Sin censura	5.2636	5.3367	2.7071	5.2636	8.0412
Con censura	5.3387	5.4087	2.7613	5.3387	8.1265

Para la interpretación de las tablas: Intuición rápida

- $S(t)$: probabilidad de seguir sin evento en el tiempo t .
- $F(t)$: probabilidad de haber tenido el evento antes del tiempo t .
- $h(t)$: tasa instantánea a la que cae $S(t)$; si $h(t)$ sube, $S(t)$ cae más rápido.
- $H(t)$: riesgo acumulado

Preguntas

- ¿Cuáles serían las aplicaciones de gestión de este análisis?

Referencias

- Cavalcante, T., Ospina, R., Leiva, V., Cabezas, X., & Martin-Barreiro, C. (2023). Weibull regression and machine learning survival models: Methodology, comparison, and application to biomedical data related to cardiac surgery. *Biology*, 12(3), 442.
- Fenina, S., Jendoubi, S., & Bouchoucha, F. (2023). Failure rate estimation by Weibull distribution in a stochastic environment: application to the hemodialysis machine. *Reliability: Theory & Applications*, 18(3 (74)), 450-463.
- Nketiah, E. A. (2021). Parameter Estimation of the Weibull Distribution; Comparison of the Least-Squares Method and the Maximum Likelihood Estimation. *Int. J. Adv. Eng. Res. Sci*, 8, 210-224.